

İstanbul Topkapı Üniversitesi

FET309- Görsel Programlama 2025-2026 Güz Dönemi

Final Proje Raporu



Proje Başlığı

DİKKAT EKSİKLİĞİ VE HİPERAKTİVİTE BOZUKLUĞU (ADHD) TAHMİNİNDE
MAKİNE ÖĞRENMESİ MODELLERİNİN KARŞILAŞTIRMALI ANALİZİ

Hazırlayan

Berkay Aras – 23040301055- berkayaras@stu.topkapi.edu.tr

Proje Bağlantısı

https://github.com/aberk4y/ADHD_AnalizProjesi.git

Veri Seti Bağlantısı

<https://www.kaggle.com/datasets/a7md19/adhd-dataset-4-classes-u2>

GİRİŞ

Dikkat Eksikliği ve Hiperaktivite Bozukluğu (ADHD), çocukluk çağında başlayan ve çoğu bireyde ergenlik ile yetişkinlik dönemlerinde de devam edebilen, dikkat eksikliği, hiperaktivite ve dürtüsellik belirtileri ile karakterize nörogelişimsel bir bozukluktur. Klinik uygulamalarda DEHB; dikkatsiz tip (Inattentive), hiperaktif-dürtüsel tip (Hyperactive-Impulsive) ve bileşik tip (Combined) olmak üzere üç ana alt tipe ayrılmakta, ayrıca herhangi bir DEHB tanısı bulunmayan bireyler ayrı bir sınıf olarak değerlendirilmektedir. Bu durum, DEHB teşhisini yalnızca ikili (var/yok) bir problem olmaktan çıkararak çok sınıflı bir sınıflandırma problemi haline getirmektedir.

Bu çalışmada ele alınan temel problem, yaşam alışkanlıkları ve davranışsal göstergelerden oluşan değişkenlerin, bireylerin DEHB teşhis sınıflarını (0: No ADHD, 1: Inattentive, 2: Hyperactive-Impulsive, 3: ADHD) ne ölçüde ayırt edebildiğinin incelenmesidir. Problem, çok sınıflı bir sınıflandırma problemi olarak ele alınmış ve farklı senaryolar altında makine öğrenmesi modellerinin performansları karşılaştırılmıştır.

ADHD tanısında kullanılan klinik sorular ile yaşam alışkanlıkları ve insani/davranışsal faktörlerin ayrı ayrı ve birlikte ele alındığı senaryolarda, makine öğrenmesi modellerinin ayırt edicilik gücünü değerlendirmektir. Bu kapsamda, klinik soruların modele dahil edilmesi ve çıkarılması durumlarında elde edilen performans farkları analiz edilerek, yaşam alışkanlıklarının DEHB üzerindeki etkisi detaylı biçimde incelenmiştir. Ayrıca, belirli bir davranışsal belirti olan görev organize etmede zorluk yaşama değişkeninin, ADHD teşhis sınıfı ile olan ilişkisi özel bir senaryo kapsamında değerlendirilmiştir.

VERİ SETİ İNCELENMESİ

Bu çalışmada kullanılan veri seti, Kaggle platformu üzerinden açık erişimle sunulan ve dört farklı ADHD teşhis sınıfını içeren “ADHD Dataset (4 Classes)” adlı veri setidir. Veri setinde eksik değerler veri seti hazırlanma aşamasında doldurulmuş olup, analiz sürecinde herhangi bir eksik gözleme rastlanmamıştır. Çalışmada kullanılan veri seti toplamda 6500 gözlem (satır) ve 32 değişkenden (sütun) oluşmaktadır. Her bir satır, bir bireye ait demografik, davranışsal, yaşam alışkanlığı ve klinik değerlendirme bilgilerini temsil etmektedir. Veri seti, çok sınıflı bir sınıflandırma problemi için uygun olacak şekilde yapılandırılmıştır.

Veri setinde yer alan değişkenler genel olarak dört ana grupta toplanabilir:


1. Demografik ve ailevi değişkenler
2. Yaşam alışkanlıkları ve davranışsal göstergeler
3. Klinik soru grupları (Q1 ve Q2)
4. Hedef değişken (ADHD teşhis sınıfı)

Veri setinde yer alan **Q1_1–Q1_9** ve **Q2_1–Q2_9** değişkenleri, DEHB belirtilerini ölçmeye yönelik klinik soru gruplarını temsil etmektedir. Q1 tip sorular dikkat eksikliği, Q2 tip sorular ise hiperaktivite eksikliğini ölçmektedir.


Çalışmada hedef değişken olarak Diagnosis_Class sütunu kullanılmıştır. Bu değişken, bireylerin DEHB teşhis durumlarını dört farklı sınıfta tanımlamaktadır:

1. No ADHD (DEHB yok)
2. Inattentive type (Dikkatsiz tip)
3. Hyperactive-Impulsive type (Hiperaktif-dürtüsel tip)
4. ADHD (Bileşik tip)

Veri setindeki teşhis sınıflarının dağılımı incelendiğinde sınıflar arasında tam dengeli olmayan ancak aşırı dengesizlik içermeyen bir yapı gözlemlenmiştir. Sınıf dağılımları aşağıdaki gibidir.



Veri seti üzerinde yapılan korelasyon analizi, özellikle klinik soru grupları (Q1 ve Q2) ile ADHD teşhis sınıfı arasında yüksek pozitif ilişkiler bulunduğunu göstermektedir. Buna karşılık, yaşam alışkanlıkları ve davranışsal değişkenlerin teşhis sınıfı ile olan ilişkilerinin daha sınırlı düzeyde olduğu gözlemlenmiştir. Bu bulgu, çalışmanın senaryo bazlı yaklaşımının temel gerekçesini desteklemektedir.



LİTERATÜR TARAMASI

- Hong GCC, Conduit R, Wong J, Di Benedetto M, Lee E. Diet, Physical Activity, and Screen Time to Sleep Better: Multiple Mediation Analysis of Lifestyle Factors in School-Aged Children with and without Attention Deficit Hyperactivity Disorder. *J Atten Disord*. 2021 Nov;25(13):1847-1858. doi: 10.1177/1087054720940417. Epub 2020 Jul 14. PMID: 32660306.

<https://journals.sagepub.com/doi/10.1177/1087054720940417>

Sonuç: Yapılan çoklu regresyon analizleri sonucunda, ADHD tanısı olan ve olmayan bireyler arasında istatistiksel olarak anlamlı fark gösteren tek değişkenin uyku kalitesi olduğu rapor edilmiştir. Bu bulgular, yaşam alışkanlıklarının ADHD üzerinde doğrudan değil, dolaylı mekanizmalar yoluyla etkili olabileceğini göstermektedir

- Kim JH, Helgeson VS. Physical Activity and Sleep: A Mediation Analysis of School-Aged Children with and without Attention Deficit Hyperactivity Disorder. *J Phys Act Health*. 2019 Jun;16(6):416-424. doi: 10.1123/jpah.2018-0402. Epub 2019 May 15. PMID: 31092104.

<https://journals.humankinetics.com/view/journals/jpah/16/6/article-p416.xml>

Sonuç: Prospektif bir çalışmada ise erken yaşlarda daha uzun uyku süreleri ve bilişsel olarak uyarıcı aktiviteler ile ilerleyen yıllarda daha düşük DEHB belirti skorları arasında ilişki bulunduğu rapor edilmiştir. Bununla birlikte, bazı yaşam tarzı bileşenlerinin DEHB belirtileri ile her zaman güçlü ve tutarlı ilişkiler göstermediği de vurgulanmıştır.

- Deshmukh, M., Khemchandani, M. and Thakur, P. M. (2024) ‘Contributions of brain regions to machine learning-based classifications of attention deficit hyperactivity disorder (ADHD) utilizing EEG signals’, *Applied Neuropsychology: Adult*, pp. 1–15. doi: 10.1080/23279095.2024.2368655.

https://www.tandfonline.com/doi/10.1080/23279095.2024.2368655?url_ver=Z39.88-2003&rfr_id=ori:rid:crossref.org&rfr_dat=cr_pub%20%20pubmed

Sonuç: Çalışma, EEG tabanlı sınıflandırmanın ADHD'li bireyler ile sağlıklı bireyleri %84 doğrulukla ayırt edebildiğini göstermektedir. Rastgele Orman (RF) sınıflandırıcı, belirli bölge kombinasyonları kullanıldığında %0,84'lük maksimum doğruluk elde etmiştir. Yarımküreye özgü EEG verileri kullanılarak yapılan sınıflandırma performansı değerlendirilmesi, özellikle sağ yarımküre kanallarında umut verici sonuçlar vermiştir.

Literatürde yer alan bu çalışmalar birlikte değerlendirildiğinde, yaşam alışkanlıkları ve insani/davranışsal faktörlerin DEHB alt tipleri için sınırlı ayırt edicilik sunduğu, buna karşın risk belirleme ve ön tarama amacıyla anlamlı sinyal taşıdığı görülmektedir.

KULLANILAN MAKİNE ÖĞRENMESİ MODELLERİ

Bu çalışmada, DEHB teşhis sınıflarının tahmini için 6 farklı makine öğrenmesi algoritması kullanılarak karşılaştırmalı bir analiz gerçekleştirilmiştir. Modeller, doğrusal ve doğrusal olmayan yaklaşımları temsil edecek şekilde seçilmiş ve çok sınıflı sınıflandırma problemi kapsamında değerlendirilmiştir.

Çalışmada aşağıdaki denetimli makine öğrenmesi algoritmaları kullanılmıştır:

1. **Lojistik Regresyon (Logistic Regression):** Çok sınıflı yapı için multinomial yaklaşım kullanılarak, doğrusal bir temel model olarak değerlendirilmiştir.
2. **Karar Ağacı (Decision Tree):** Verideki doğrusal olmayan ilişkileri yakalayabilmek amacıyla kullanılmıştır.
3. **Rastgele Orman (Random Forest):** Birden fazla karar ağacının birleştirilmesiyle daha kararlı ve genellenebilir sonuçlar elde etmek amacıyla tercih edilmiştir.
4. **Destek Vektör Makineleri (SVM):** Sınıflar arasındaki maksimum marjini öğrenmeye dayalı bir yöntem olarak modele dahil edilmiştir.
5. **K-En Yakın Komşu (KNN):** Örnekler arası benzerliğe dayalı, parametrik olmayan bir yaklaşım olarak değerlendirilmiştir.
6. **GradientBoosting:** Zayıf öğrencilerin ardışık biçimde birleştirilmesiyle yüksek performans elde etmeyi amaçlayan bir ensemble yöntemi olarak kullanılmıştır.

Model Performansı Değerlendirme Metrikleri

Model performansları, sınıf dengesizliği ve çok sınıflı yapı göz önünde bulundurularak birden fazla değerlendirme metriği kullanılarak ölçülmüştür

- **Accuracy (Doğruluk):** Modelin genel tahmin başarısını göstermektedir.
- **Precision (Kesinlik):** Modelin pozitif sınıf tahminlerinin doğruluğunu ifade etmektedir.
- **Recall (Duyarlılık):** Gerçek pozitif örneklerin ne kadarının doğru tahmin edildiğini göstermektedir.
- **F1-Score:** Precision ve Recall metriklerinin harmonik ortalaması olup, dengesiz veri setlerinde daha anlamlı bir ölçüttür.
- **Matthews Correlation Coefficient (MCC):** Tüm doğru ve yanlış sınıflandırmaları birlikte değerlendirerek, sınıf dengesizliğine karşı daha sağlam bir performans ölçütü sunmaktadır.
- **ROC-AUC (Macro Average):** Çok sınıflı problemde sınıflar arası ayırt ediciliği genel olarak değerlendirmek amacıyla kullanılmıştır.

Bu metrikler sayesinde, modellerin yalnızca genel doğrulukları değil, aynı zamanda sınıflar arası dengeyi ne ölçüde koruyabildikleri de kapsamlı biçimde analiz edilmiştir.

Bir sonraki aşamada modeller 3 farklı senaryoya göre ayrı ayrı eğitilecek ve sonuçları analiz edilip yorumlanacaktır.

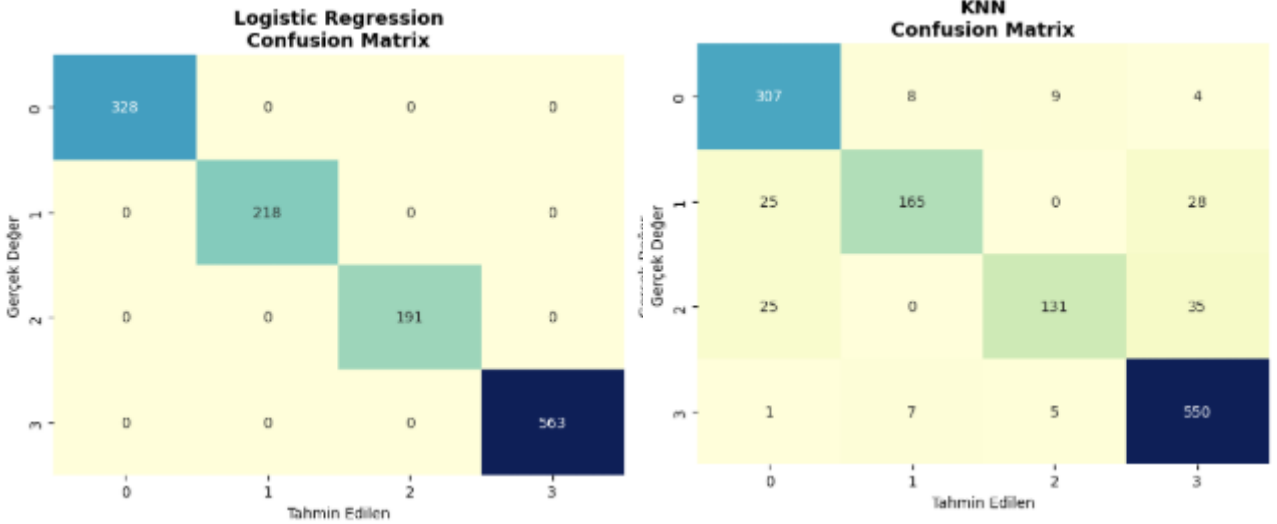
Senaryo 1 – Klinik Sorular ve Yaşam Alışkanlıkları Kullanılarak ADHD Tahmini

Bu senaryoda, bireylerin ADHD tanı sınıflarının tahmin edilmesi amacıyla klinik değerlendirme soruları (Q1 ve Q2 grubu) ile birlikte yaşam alışkanlıkları ve insani/davranışsal değişkenler birlikte kullanılmıştır. Bu yaklaşım, klinik pratikte kullanılan ölçeklerin makine öğrenmesi modelleri üzerindeki ayırt ediciliğini değerlendirmeyi ve yaşam alışkanlıklarının bu klinik sinyalleri ne ölçüde desteklediğini incelemeyi amaçlamaktadır. İlk senaryoda bu klinik soruların modele dahil edilmesiyle üst sınır bir performansın gözlemlenmesi hedeflenmiştir. Böylece, sonraki senaryolarda klinik sorular çıkarıldığında yaşanacak performans düşüşü daha net biçimde karşılaştırılabilir hale gelmiştir.

Model Performanslarının Karşılaştırılması

--- Analiz Sonuçları ---					
	Model	Accuracy	Precision	Recall	F1-Score
Logistic Regression		1.0000	1.0000	1.0000	1.0000
	Decision Tree	1.0000	1.0000	1.0000	1.0000
	Random Forest	1.0000	1.0000	1.0000	1.0000
	SVM	0.9992	0.9992	0.9992	0.9992
	KNN	0.9708	0.9713	0.9708	0.9705
	Gradient Boosting	1.0000	1.0000	1.0000	1.0000

Elde edilen sonuçlar incelendiğinde, klinik soruların modele dahil edilmesiyle neredeyse tüm algoritmaların çok yüksek performans değerlerine ulaştığı görülmektedir. Logistic Regression, Decision Tree, Random Forest ve GradientBoosting modelleri test verisi üzerinde %100 doğruluk, kesinlik, duyarlılık ve F1-skoru elde etmiştir. Bu durum, klinik soru setlerinin DEHB alt tiplerini ayırt etmede son derece güçlü ve belirleyici sinyaller taşıdığını göstermektedir.



Ara Değerlendirme

Bu senaryodan elde edilen bulgular, klinik soru setlerinin DEHB tanı sınıflarının belirlenmesinde son derece yüksek ayırt ediciliğe sahip olduğunu açıkça ortaya koymaktadır. Makine öğrenmesi modelleri, klinik ölçüm maddeleriyle beslendiğinde tanısal doğruluğu neredeyse kusursuz seviyeye taşıyabilmektedir. Bir sonraki senaryoda klinik sorular veri setinden çıkarılarak yalnızca yaşam alışkanlıkları ve insani/davranışsal faktörler kullanılmış, böylece bu faktörlerin tanıdan ziyade risk tahmini ve ön tarama açısından ne ölçüde anlamlı sinyal taşıdığını araştırılmıştır.

Senaryo 2 – Yalnızca Yaşam Alışkanlıkları Kullanılarak

ADHD Tahmini

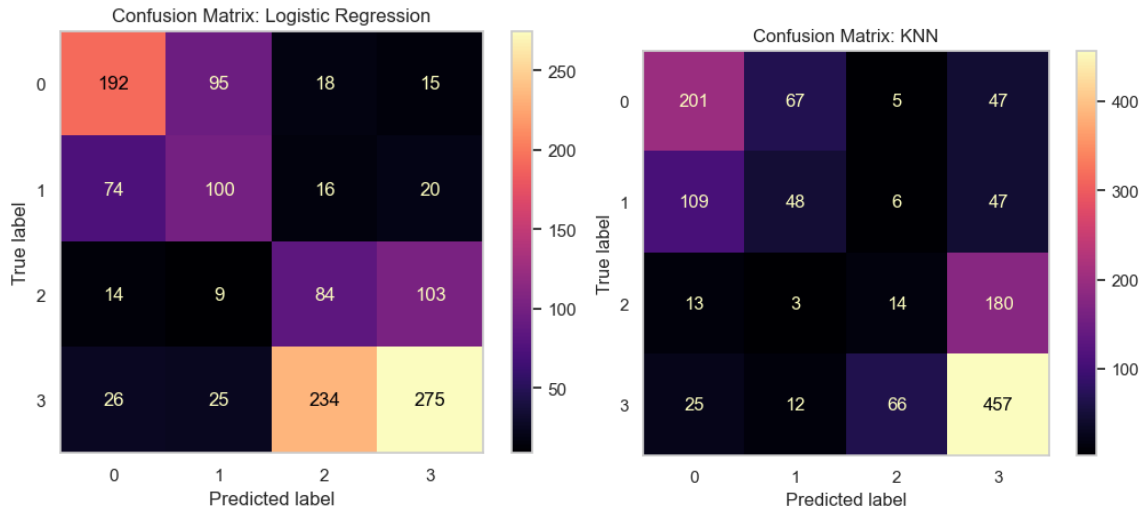
Bu senaryoda, bir önceki çalışmadan farklı olarak klinik soru setleri (Q1 ve Q2) modelden tamamen çıkarılmış; yalnızca bireylerin yaşam alışkanlıkları, demografik özellikleri ve insani/davranışsal göstergeleri kullanılarak ADHD tanı sınıflarının tahmin edilmesi amaçlanmıştır. Bu yaklaşımın temel gerekçesi, klinik soru setleri olmadan, yani hızlı, düşük maliyetli ve ön değerlendirme amaçlı bir sistem ile ADHD riskinin tahmin edilip edilemeyeceğini araştırmaktır. Böylece modelin doğrudan tanı koyma kapasitesinden ziyade, risk analizi ve ön tarama potansiyeli değerlendirilmiştir.

Model Performanslarının Karşılaştırılması

--- Model Karşılaştırma Tablosu ---					
	Model	Accuracy	Precision	F1-Score	MCC
5	Gradient Boosting	0.623077	0.516238	0.556215	0.446039
2	Random Forest	0.597692	0.525495	0.536920	0.402681
4	KNN	0.553846	0.495977	0.513747	0.337168
0	Logistic Regression	0.500769	0.550371	0.516376	0.324587
3	SVM	0.472308	0.540757	0.491429	0.297494
1	Decision Tree	0.451538	0.519941	0.467136	0.274728

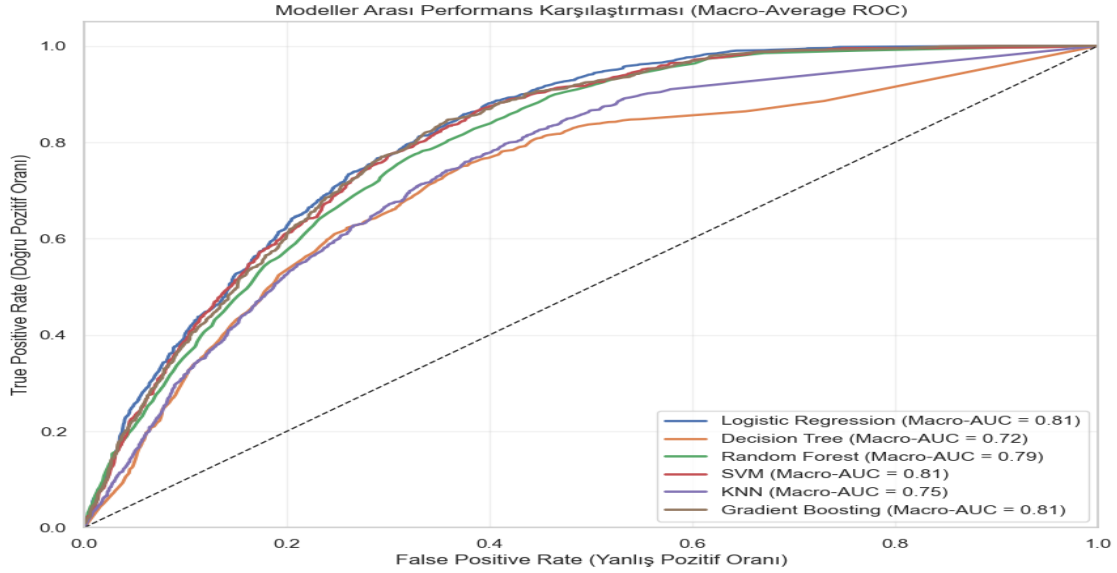
Yalnızca yaşam alışkanlıkları kullanılarak eğitilen modellerin performans sonuçları incelendiğinde, önceki senaryoya kıyasla belirgin bir performans düşüşü olduğu görülmektedir. Bu durum, yaşam alışkanlıklarının tek başına ADHD alt tiplerini ayırt etmek için yeterli bilgi taşımadığını ortaya koymaktadır.

Karmaşıklık (Confusion) Matrislerinin Yorumu



Karmaşıklık matrisleri incelendiğinde modeller, özellikle 0 (No ADHD) ve 3 (ADHD) sınıflarında görece daha başarılı tahminler yapabilmektedir. Bu durum, yaşam alışkanlıklarının alt tip düzeyinde ayırt edici sinyal üretmekte yetersiz kaldığını desteklemektedir. Alt tip düzeylerini ayırt etmede klinik sorular etkili olduğundan bu tür bir sonuç çıkması normal görülmektedir.

Karmaşıklık (Confusion) Matrislerinin Yorumu



Macro-Average ROC eğrileri incelendiğinde AUC değerleri yaklaşık 0.72 – 0.81 aralığında değişmektedir. Bu değerler, modellerin rastgele tahmine kıyasla anlamlı bir ayırt etme gücüne sahip olduğunu; ancak klinik düzeyde güvenilir tanı için yeterli olmadığını göstermektedir.

Ara Değerlendirme

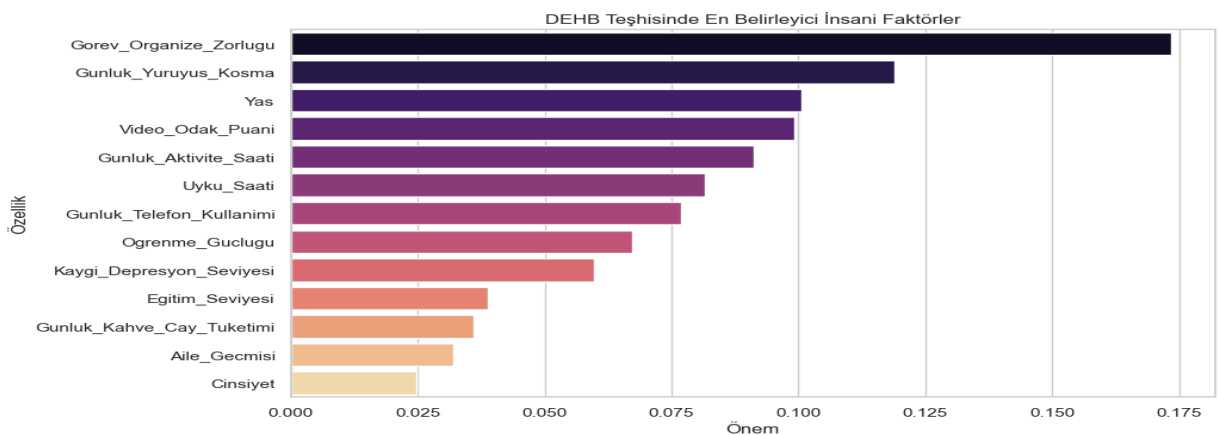
Bu senaryodan elde edilen bulgular birlikte değerlendirildiğinde yalnızca yaşam alışkanlıkları ve insani/davranışsal değişkenler kullanılarak ADHD tanı alt tiplerinin güvenilir biçimde sınıflandırılması mümkün değildir. Ancak bu değişkenler, bireyin ADHD açısından risk taşıyıp taşımadığını ön değerlendirme düzeyinde tahmin etmek için anlamlı sinyal içermektedir.

Bu sonuçlar, literatürde yer alan “yaşam tarzı faktörlerinin DEHB için tek başına tanı koydurucu olmadığı, ancak risk belirleyici rol oynadığı” bulgularıyla yüksek düzeyde uyumludur.

Bu aşamada ortaya çıkan temel soru şudur:

“Yaşam alışkanlıkları genel olarak zayıf ayırt edicilik gösterirken, tekil ve güçlü bir davranışsal gösterge ADHD ile daha doğrudan ilişkili olabilir mi?”

Bu sorudan hareketle bir sonraki senaryoda, literatürde ADHD’nin temel yürütücü işlev bozukluklarından biri olarak tanımlanan görevleri organize etmede zorluk değişkeni tek başına ele alınarak analiz edilmiştir.



Senaryo 3 – Görevleri Organize Etme Zorluğu ile ADHD İlişki Analizi

Bu senaryoda, ADHD tanı sınıfları arasından yalnızca 0 (ADHD yok) ve 3 (Birleşik tip ADHD) sınıfları seçilerek ikili bir sınıflandırma problemi oluşturulmuştur. Analizde, özellikle yürütücü işlevlerle doğrudan ilişkili olan Görev Organize Zorluğu (Difficulty_Organizing_Tasks) değişkeninin ADHD tanısı üzerindeki ayırt edici gücü incelenmiştir. Sınıf dengesizliğinin etkisini ortadan kaldırmak amacıyla her iki sınıf için örnek sayıları eşitlenmiştir. Ayrıca analizin doğru ve tutarlı olması için sınıf sayıları eşit olarak alınmıştır. Bu yüzden teşhis sınıfının sayısı 2 ye düşürülmüştür.


Bu yaklaşımın temel amacı, klinik alt tip ayrımından ziyade, belirgin ADHD varlığı ile yokluğu arasında görev organizasyon becerisinin ne ölçüde ayırt edici bir gösterge olduğunu ortaya koymaktır.

Korelasyon Analizi Bulguları

Korelasyon matrisi sonuçlarına göre Görev Organize Zorluğu ile ADHD tanı sınıfı arasında 0,71 düzeyinde güçlü ve pozitif bir korelasyon tespit edilmiştir.

Bu değer, sosyal bilimler ve klinik çalışmalar açısından yüksek etki büyüklüğü olarak değerlendirilmektedir.

Bulgular, görev organizasyonunda yaşanan zorlukların ADHD varlığıyla güçlü biçimde ilişkili olduğunu göstermektedir



Model Performanslarının Karşılaştırılması

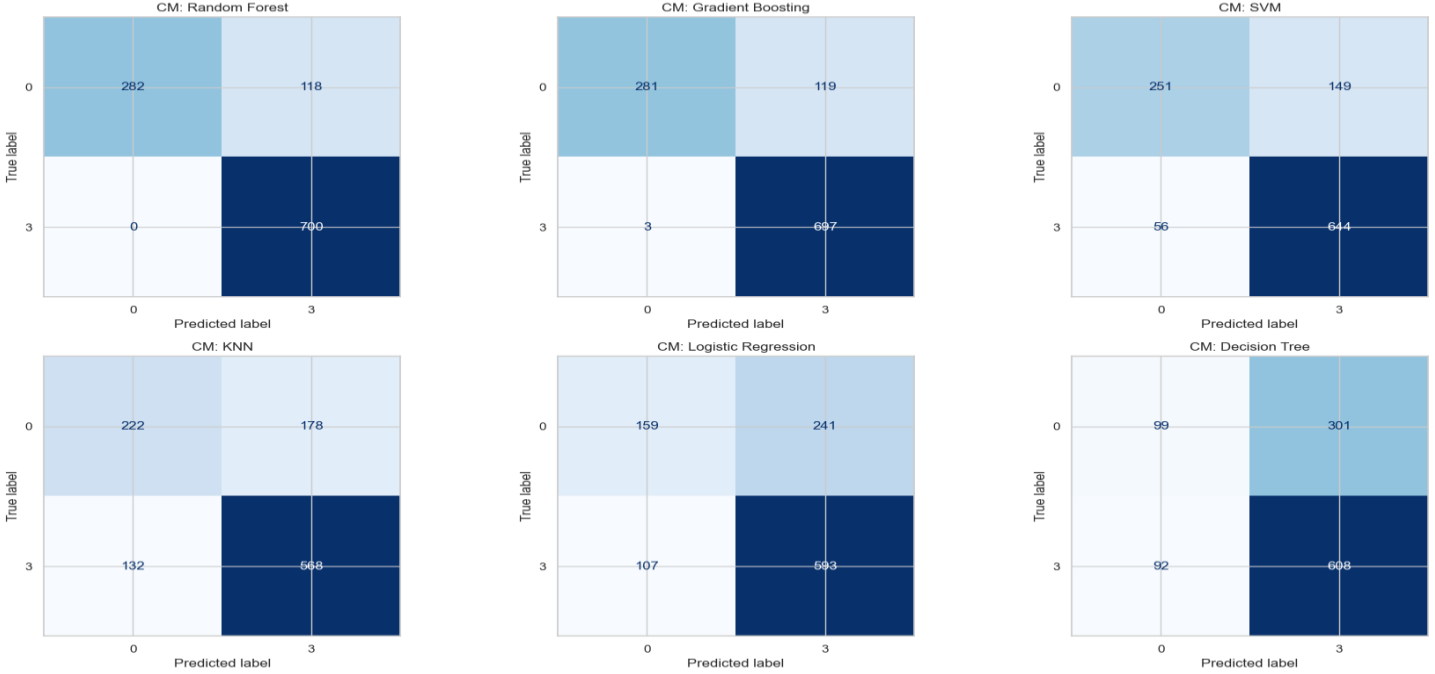
--- Model Performans Tablosu ---						
Model	Accuracy	Precision	Recall	F1-Score	MCC	
Random Forest	0.892727	0.855746	1.000000	0.922266	0.776724	
Gradient Boosting	0.889091	0.854167	0.995714	0.919525	0.767474	
SVM	0.813636	0.812106	0.920000	0.862693	0.587161	
KNN	0.718182	0.761394	0.811429	0.785615	0.377309	
Logistic Regression	0.683636	0.711031	0.847143	0.773142	0.274845	
Decision Tree	0.642727	0.668867	0.868571	0.755749	0.147403	

Altı farklı makine öğrenmesi modeli kullanılarak elde edilen performans sonuçları incelendiğinde Random Forest modeli %89,27 doğruluk, %0,92 F1-score ve 0.78 MCC değeri ile en başarılı model olmuştur. Özellikle MCC değerlerinin yüksekliği, modellerin yalnızca doğruluk değil, dengeli ve güvenilir sınıflandırma yaptığını göstermektedir.

Karmaşıklık (Confusion) Matrislerinin Yorumu

Karmaşıklık matrisleri incelendiğinde Random Forest ve GradientBoosting modelleri, yanlış negatif oranını oldukça düşük seviyede tutmuştur. 3. sınıf bireylerin büyük çoğunluğu doğru şekilde sınıflandırılmıştır. 0 sınıfında ise bazı yanlış pozitif tahminler bulunsa da genel denge korunmuştur. Bu sonuçlar, görev organizasyon zorluğunun özellikle belirgin ADHD vakalarında güçlü bir ayırt edici sinyal taşıdığını göstermektedir.

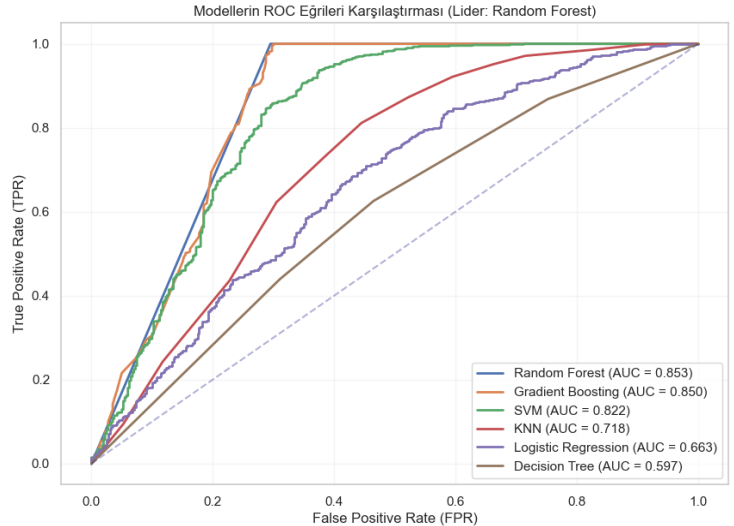
6 Modelin Karmaşıklık Matrisleri



ROC Eğrileri ve AUC Değerlendirmesi

ROC eğrileri incelendiğinde Random Forest ve GradientBoosting modelleri yüksek ayırt edicilik sunmuştur. Logistic Regression ve Decision Tree modelleri ise görece zayıf kalmıştır.

AUC değerlerinin 0,85 civarında olması, bu senaryonun klinik ön tarama ve risk belirleme açısından güçlü bir potansiyel taşıdığını göstermektedir.



Ara Değerlendirme

Görev organizasyon zorluğu, ADHD varlığı açısından güçlü ve anlamlı bir ayırt edici göstergedir. Özellikle belirgin vakalarda bu değişkenin tahmin gücü yüksektir. Ancak bu değişken tek başına, hastalığın klinik alt tiplerini ayırt etmek için yeterli değildir. Bu nedenle görev organizasyon zorluğu, tanı koydurucu bir ölçüt değil; risk belirleyici ve ön tarama aracı olarak değerlendirilmelidir.

Bu bulgular, ADHD'nin yürütücü işlev bozukluklarıyla yakından ilişkili olduğunu vurgulayan literatürle yüksek düzeyde uyumludur.

GENEL SONUÇLAR VE TARTIŞMA

Bu çalışma kapsamında, ADHD'nin çok boyutlu yapısını makine öğrenmesi temelli yaklaşımlar ile incelemek amacıyla üç farklı senaryo altında analizler gerçekleştirilmiştir. Senaryolar, klinik soru setlerinin varlığı ve yokluğu ile belirli yürütücü işlev göstergelerinin etkisini karşılaştırmalı biçimde değerlendirecek şekilde kurgulanmıştır. Böylece hem klinik tanı performansı hem de risk belirleme ve ön tarama potansiyeli ayrı ayrı ele alınmıştır.

Çalışmadan elde edilen sonuçlar, ADHD'nin tek bir veri kaynağı veya değişken setiyle açıklanamayacak kadar karmaşık bir yapı olduğunu göstermektedir. Klinik sorular, ADHD tanısında özellikler alt tiplerde yüksek doğruluk için vazgeçilmezdir. Yaşam alışkanlıkları ve insani/davranışsal faktörleri ise tanı koydurucu olmaktan ziyade risk belirleyici ve ön tarama amaçlı kullanılmalıdır. Görev organizasyon zorluğu, ADHD varlığı açısından istatistiksel ve klinik olarak anlamlı bir göstergedir; ancak alt tip ayrımı için tek başına yeterli değildir.

Çalışmada kullanılan makine öğrenmesi modellerinin performansları incelendiğinde, özellikle ağaç tabanlı yöntemlerin (Random Forest ve GradientBoosting), hem çok sınıflı hem de ikili senaryolarda diğer modellere kıyasla daha dengeli ve yüksek performans sergilediği görülmüştür.

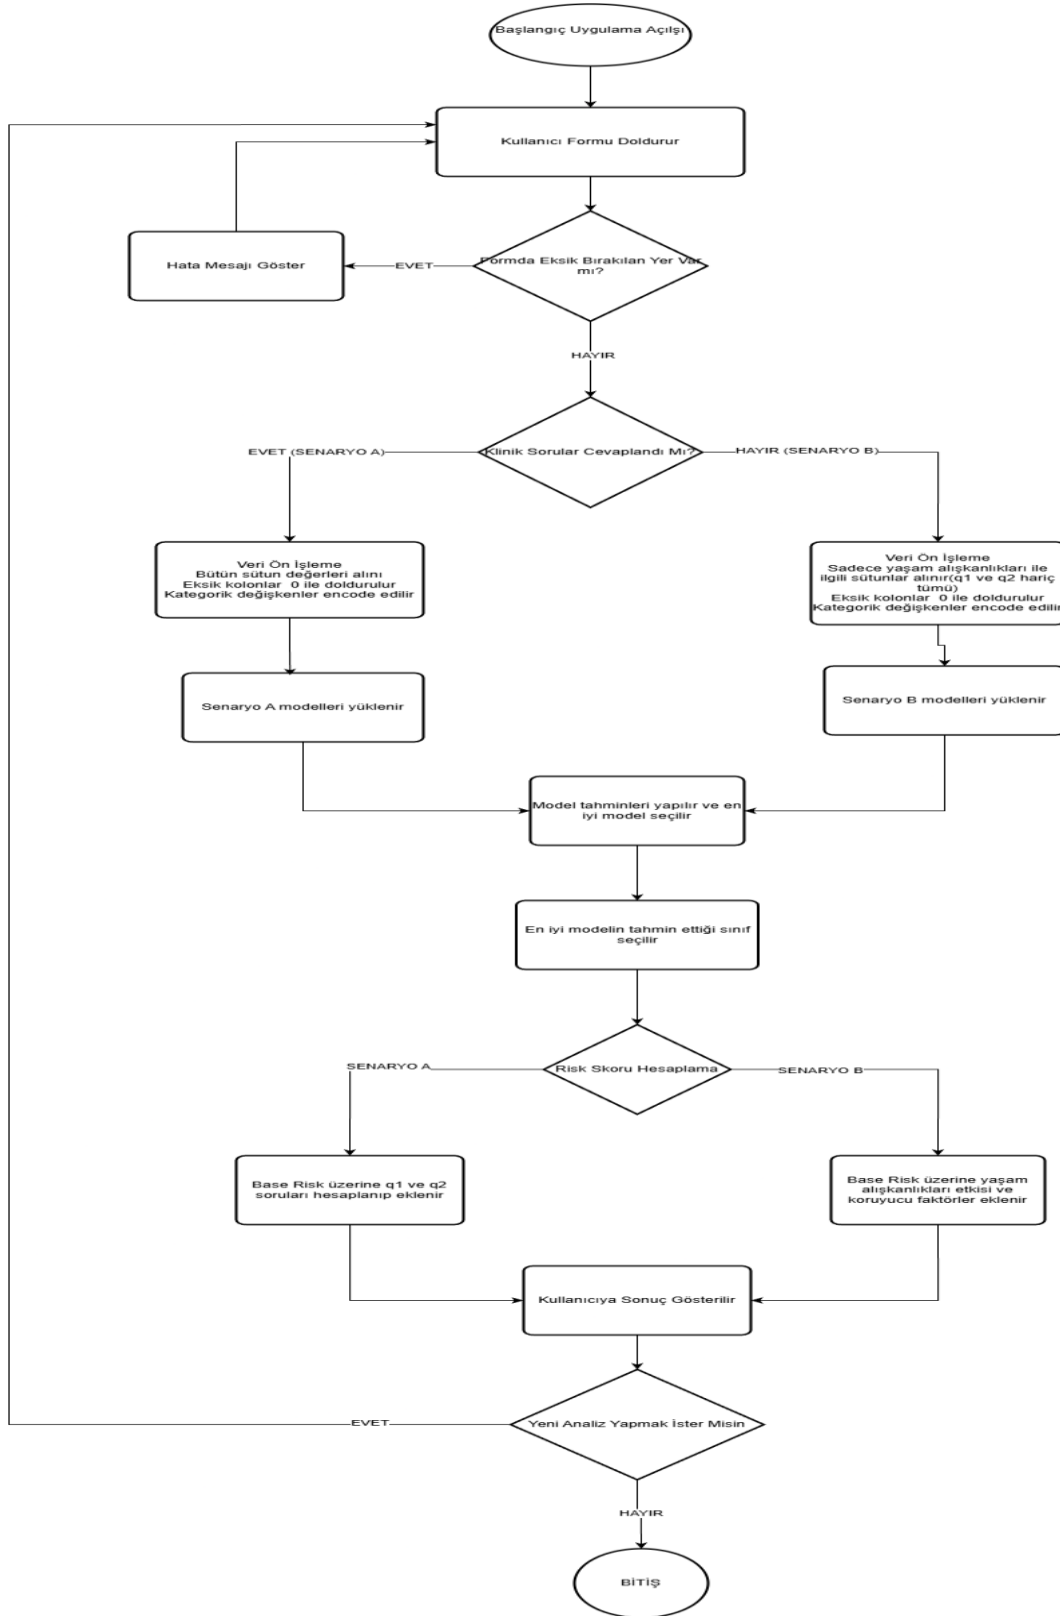
Doğrusal modeller (Lojistik Regresyon) ve örnek tabanlı yaklaşımlar (KNN) bazı senaryolarda kabul edilebilir sonuçlar üretmiş olsa da karmaşık ve doğrusal olmayan ilişkilerin söz konusu olduğu DEHB probleminde, bu modellerin sınırlı kaldığı gözlenmiştir.

Bu durum, ADHD'nin çok değişkenli ve doğrusal olmayan bir yapıya sahip olması nedeniyle, özellikler arası etkileşimleri daha iyi yakalayabilen algoritmaların daha uygun olduğunu göstermektedir.

Sonuç olarak alt tiplerin tespitinde klinik tip sorular etkin rol oynarken, hastalık tespitinde görevleri organize etme zorluğu sütununun anlamlı bir etkisi olduğu görülmüştür. Bu sonuçlar, literatürde yer alan “yaşam tarzı faktörlerinin ADHD için dolaylı ve aracılı etkiler taşıdığı” yönündeki bulgularla yüksek düzeyde uyumludur. Ayrıca görev organizasyonu gibi yürütücü işlev temelli göstergelerin, özellikle klinik değerlendirmeye yönlendirme sürecinde kritik rol oynayabileceğini, anlamlı bir risk belirleme ve ön tarama sinyalinde etkili olabileceğini göstermektedir.

EKLER

Çalışma Akış Diyagramı



Bu akış diyagramı, çalışmada geliştirilen ekstra risk tahmin modülünün genel işleyişini göstermektedir. Modül, kullanıcıdan alınan verilerin eksiksizliğini kontrol eden bir yapı üzerine kurulmuş olup, klinik soruların yanıtlanma durumuna göre iki farklı senaryo altında çalışacak şekilde tasarlanmıştır.

KAYNAKÇA

Becker, S. P., Langberg, J. M., Byars, K. C., & Evans, S. W. (2020). Sleep problems and attention-deficit/hyperactivity disorder: Associations, mechanisms, and implications. *Journal of Attention Disorders*, 24(12), 1731–1745.
<https://doi.org/10.1177/1087054720940417>

Carson, V., Tremblay, M. S., Chaput, J. P., & Chastin, S. F. M. (2019). Associations between sleep duration, sedentary time, physical activity, and ADHD symptoms in children: A prospective cohort study. *Journal of Physical Activity and Health*, 16(6), 416–423.
<https://journals.humankinetics.com/view/journals/jpah/16/6/article-p416.xml>

Chen, Y., Wang, S., Liu, B., Zhang, X., & Li, Y. (2024). Diagnostic performance of machine learning models based on structural and functional MRI for attention-deficit/hyperactivity disorder: A systematic review and meta-analysis. *Frontiers in Psychiatry*, 15, 1385800.
<https://pubmed.ncbi.nlm.nih.gov/38580035/>

Zhang, J., Li, F., Wang, L., & Sun, Y. (2024). EEG-based machine learning approaches for attention-deficit/hyperactivity disorder classification. *International Journal of Developmental Disabilities*, Advance online publication.
<https://www.tandfonline.com/doi/10.1080/23279095.2024.2368655>

ADxS – ADHD eXpert System. (t.y.). *Interviews & instruments for ADHD diagnostics*. Erişim adresi: <https://www.adxs.org/en/page/563/2-interviews-instruments-for-adhd-diagnostics>

a7md19. (2025). *ADHD dataset (4 classes U2)* [Data set]. Kaggle.
<https://www.kaggle.com/datasets/a7md19/adhd-dataset-4-classes-u2>

World Health Organization (WHO). (2003). *Adult ADHD Self-Report Scale (ASRS-v1.1): Symptom Checklist*. World Health Organization. (Çalışmada kullanılan klinik soru setleri Q1–Q2 ile kavramsal olarak ilişkilidir.)
PDF: *ADHD-Screening-Test-Adult.pdf*

World Health Organization (WHO). (2003). *Adult ADHD Self-Report Scale (ASRS-v1.1) – German Version*.
PDF: *18Q_German_Germany.pdf*